Práctica Orquestación

Apache Airflow

Username: airflow Password: airflow



http://<direccion ip>:8010



Veremos cómo crear un pipeline a través de un DAG, creando las tareas:

- Ingest
- Transform
- Load

Ingest (/home/hadoop/scripts/ingest.sh)

```
##borro todo del directorio landing
rm -f /home/hadoop/landing/*

##obtengo los files
wget -P /home/hadoop/landing https://<url>/yellow_tripdata_2021-01.parquet

##borro el contenido del directorio de HDFS /ingest
/home/hadoop/hadoop/bin/hdfs dfs -rm -f /ingest/*

##copio todo el contenido del directorio /landing en /ingest
/home/hadoop/hadoop/bin/hdfs dfs -put /home/hadoop/landing/* /ingest
```

```
##obtengo los files
wget -P /home/hadoop/landing https://d37ci6vzurychx.cloudfront.net/trip-data/yellow_tripdata_2021-01.>
##borro el contenido del directorio de HDFS /ingest
/home/hadoop/hadoop/bin/hdfs dfs -rm -f /ingest/*

##copio todo el contenido del directorio /landing en /ingest
/home/hadoop/hadoop/bin/hdfs dfs -put /home/hadoop/landing/* /ingest
```

Transform & Load (/home/hadoop/scripts/transformation.py)

```
from pyspark.context import SparkContext
from pyspark.sql.session import SparkSession
from pyspark.sql import HiveContext
sc = SparkContext('local')
spark = SparkSession(sc)
hc = HiveContext(sc)

##leo el file desde HDFS y lo cargo en un dataframe
df = spark.read.option("header",
"true").parquet("hdfs://<direccionIP>:9000/ingest/<file>
```

Transform & Load

```
##creamos una vista del DF
df.createOrReplaceTempView("tripdata vista")
##Filtramos el DF quedándonos solamente con aquellos viajes que viajaron un
solo pasajero y tuvieron una distancia mayor a 5 millas
new df = spark.sql("select * from tripdata vista where passenger count = 1
and trip distance > 5")
##Creamos una vista con la data filtrada###
new df.createOrReplaceTempView("tripdata vista filtrada")
##insertamos el DF filtrado en la tabla tripdata table
spark.sql("insert into tripdata.tripdata table select * from
tripdata vista filtrada;")
```

```
GNU nano 4.8
                                  /home/hadoop/scripts/transformation.pv
from pyspark.context import SparkContext
from pyspark.sql.session import SparkSession
from pyspark.sql import HiveContext
sc = SparkContext('local')
spark = SparkSession(sc)
hc = HiveContext(sc)
##leo el csv desde HDFS y lo cargo en un dataframe
df = spark.read.option("header", "true").parquet("hdfs://172.20.0.2:9000/ingest/yellow tripdata 2021-0
##creamos una vista del DF
df.createOrReplaceTempView("tripdata vista")
##Filtramos el DF quedandonos solamente con aquellos viejes que viajaron un solo pasajero y tuvieron u
new df = spark.sql("select * from tripdata vista where passenger count = 1 and trip distance > 5")
##Creamos una vista con la data filtrada###
new df.createOrReplaceTempView("tripdata vista filtrada")
##insertamos el DF filtrado en la tabla tripdata table
spark.sql("insert into tripdata.tripdata table select * from tripdata vista filtrada;")
```

Creación DAG

```
from datetime import timedelta
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.operators.dummy import DummyOperator
from airflow.utils.dates import days ago
args = {
    'owner': 'airflow',
with DAG(
    dag id='ingest-transform',
    default args=args,
    schedule interval='0 0 * * *',
    start date=days ago(2),
    dagrun timeout=timedelta(minutes=60),
    tags=['ingest', 'transform'],
    params={"example key": "example value"},
) as dag:
```

Creación DAG

```
finaliza_proceso = DummyOperator(
       task id='finaliza proceso',
   ingest = BashOperator(
       task id='ingest',
        bash command='/usr/bin/sh /home/hadoop/scripts/ingest.sh ',
   transform = BashOperator(
       task id='transform',
        bash command='ssh hadoop@172.20.0.2 /home/hadoop/spark/bin/spark-submit --files
/home/hadoop/hive/conf/hive-site.xml /home/hadoop/scripts/transformation.py ',
   ingest >> transform >>finaliza proceso
if name == " main ":
    dag.cli()
```

Apache Airflow

